

# IP-LSSVM: A TWO-STEP SPARSE CLASSIFIER

AUTORES: B.P.R. CARVALHO, A.P. BRAGA

Apresentação: Paulo Sérgio Pereira Pessim

EEE928 - Técnicas Clássicas de Reconhecimento de Padrões

Programa de Pós-Graduação em Engenharia Elétrica - UFMG

Prof. Antônio Braga e Prof. Frederico Coelho



7 de Julho de 2021

# INTRODUÇÃO

- A técnica SVM (do inglês, *Support Vector Machine*) é amplamente empregada.

# INTRODUÇÃO

- A técnica SVM (do inglês, *Support Vector Machine*) é amplamente empregada.
  - Maximização de margem (Abordagem de Programação Quadrática).
  - Seleção dos Vetores de Suporte (Sensitividade dos Multiplicadores de Lagrange - Não nulos nas margens).

# INTRODUÇÃO

- A técnica SVM (do inglês, *Support Vector Machine*) é amplamente empregada.
  - Maximização de margem (Abordagem de Programação Quadrática).
  - Seleção dos Vetores de Suporte (Sensitividade dos Multiplicadores de Lagrange - Não nulos nas margens).
- Desenvolvimento de Estratégias que demandam menos recursos computacionais.

# INTRODUÇÃO

- A técnica SVM (do inglês, *Support Vector Machine*) é amplamente empregada.
  - Maximização de margem (Abordagem de Programação Quadrática).
  - Seleção dos Vetores de Suporte (Sensitividade dos Multiplicadores de Lagrange - Não nulos nas margens).
- Desenvolvimento de Estratégias que demandam menos recursos computacionais.
- *Least Squares Support Vector Machine - LSSVM*
  - Menos Recursos - Sistema de Equações Lineares.
  - Perda de '*sparseness*'.
  - Selecionar os Vetores de Suporte pelo critério *non-zero*.

# INTRODUÇÃO

- A técnica SVM (do inglês, *Support Vector Machine*) é amplamente empregada.
  - Maximização de margem (Abordagem de Programação Quadrática).
  - Seleção dos Vetores de Suporte (Sensitividade dos Multiplicadores de Lagrange - Não nulos nas margens).
- Desenvolvimento de Estratégias que demandam menos recursos computacionais.
- *Least Squares Support Vector Machine - LSSVM*
  - Menos Recursos - Sistema de Equações Lineares.
  - Perda de '*sparseness*'.
  - Selecionar os Vetores de Suporte pelo critério *non-zero*.
- A relação entre Vetores de suporte  $\times$  Custo computacional.
  - Melhorar a representação dos vetores de suporte na abordagem LSSVM.

# FORMULAÇÃO - LSSVM

- Conjunto de Treinamento  $\{x_i, y_i\}_{i=1}^N$ ,  $x_i \in \mathbb{R}^n$ ,  $y_i \in \{-1, +1\}$  é mapeado por meio de funções de kernel.

# FORMULAÇÃO - LSSVM

- Conjunto de Treinamento  $\{x_i, y_i\}_{i=1}^N$ ,  $x_i \in \mathbb{R}^n$ ,  $y_i \in \{-1, +1\}$  é mapeado por meio de funções de kernel.
- O mapeamento resulta em um problema linearmente separável na forma:

$$w^T \Phi(x) + b = 0$$

- $w$  - Vetor de Parâmetros,
- $b$  - Termo da variável de folga (*bias-term*)



# FORMULAÇÃO - LSSVM

- Conjunto de Treinamento  $\{x_i, y_i\}_{i=1}^N$ ,  $x_i \in \mathbb{R}^n$ ,  $y_i \in \{-1, +1\}$  é mapeado por meio de funções de kernel.
- O mapeamento resulta em um problema linearmente separável na forma:

$$w^T \Phi(x) + b = 0$$

- $w$  - Vetor de Parâmetros,
- $b$  - Termo da variável de folga (*bias-term*)
- Maximização de margem: Minimização da norma quadrática de  $w$  e do erro de treinamento

$$\text{Mín}_{w,b,e} \quad J_P(w, b, e) = \frac{1}{2} w^T w + \gamma \frac{1}{2} \sum_{i=1}^N e_i^2$$

sujeito a

$$y_i [w^T \phi(x) + b] = 1 - e_i, \quad i = 1, \dots, N.$$

sendo  $\gamma$  um parâmetro de margem.

# FORMULAÇÃO - LSSVM

- O Problema pode então ser reescrito como um sistema linear na forma  $AX = B$ , sendo

$$A = \begin{bmatrix} 0 & -Y^T \\ Y & H \end{bmatrix}, \quad X = \begin{bmatrix} b \\ \alpha \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

$$H = Z^T Z + \frac{I}{\gamma}, \quad Z = \begin{bmatrix} \varphi(x_1)y_1 & \dots & \varphi(x_1)y_1 \\ \vdots & \ddots & \vdots \\ \varphi(x_N)y_N & \dots & \varphi(x_N)y_N \end{bmatrix}.$$

- A saída do LSSVM pode ser computada por:

$$f(x) = \text{sign} \left[ \sum_{i=1}^N \alpha_i y_i K(x, x_i) + b \right], \quad K(x, x_i) = \varphi(x) \varphi(x_i).$$

- Os valores de  $\alpha$  serão diferentes dos obtidos pela programação quadrática, uma vez que  $\gamma$  não impõe restrições como o parâmetro  $C$ , ( $0 \leq \alpha \leq C$ ).

# VETORES DE SUPORTE - LSSVM

- Seleção de acordo com  $|\alpha|$ .




FIGURE: Vetores de Suporte LSSVM (Pontos maiores). Fonte: Artigo base

# RELAÇÃO DE MARGEM - QP-SVM

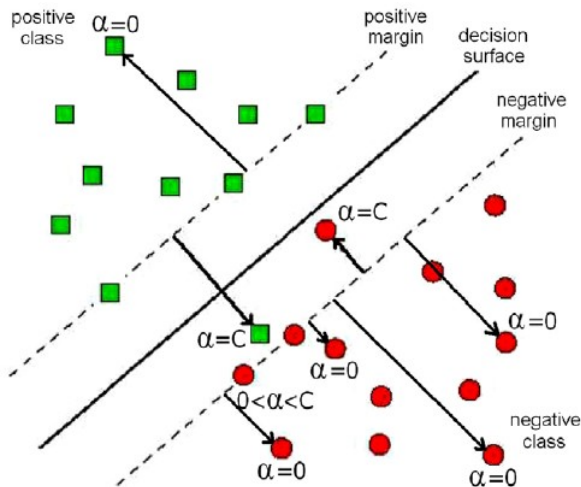


FIGURE: Valores de  $\alpha$  e sua relação com a margem QP-SVM.

# RELAÇÃO DE MARGEM - LSSVM




FIGURE: Valores de  $\alpha$  e sua relação com a margem LSSVM.

# NOVO CRITÉRIO DE RELEVÂNCIA

- $x_i$  com  $\alpha_i \gg 0$  é um vetor de suporte:  $x_i$  localizado na borda entre as duas classes, ou então na região de classe oposta (Semelhante a  $\alpha$  diferente de zero em QP-SVM).

# NOVO CRITÉRIO DE RELEVÂNCIA

- $x_i$  com  $\alpha_i \gg 0$  é um vetor de suporte:  $x_i$  localizado na borda entre as duas classes, ou então na região de classe oposta (Semelhante a  $\alpha$  diferente de zero em QP-SVM).
- $x_i$  com  $\alpha \geq 0$  é eliminado:  $x_i$  é corretamente classificado e próximo ao hiperplano de suporte (Semelhante a região com  $\alpha = 0$ ).

# NOVO CRITÉRIO DE RELEVÂNCIA

- $x_i$  com  $\alpha_i \gg 0$  é um vetor de suporte:  $x_i$  localizado na borda entre as duas classes, ou então na região de classe oposta (Semelhante a  $\alpha$  diferente de zero em QP-SVM).
- $x_i$  com  $\alpha \geq 0$  é eliminado:  $x_i$  é corretamente classificado e próximo ao hiperplano de suporte (Semelhante a região com  $\alpha = 0$ ).
- $x_i$  com  $\alpha < 0$  ou  $\alpha_i \ll 0$  é eliminado:  $x_i$  é corretamente classificado e longe da superfície de decisão (Semelhante a região com  $\alpha = 0$ ).



# VETORES DE SUPORTE UTILIZANDO O NOVO CRITÉRIO




FIGURE: Vetores de Suporte para LSSVM utilizando o critério proposto. Fonte: Artigo base

# PROCESSO DE TREINAMENTO - IP-LSSVM

- ❶ O sistema de equações lineares é resolvido com todos os vetores de treinamento,  $X = A^{-1}B$ .
- ❷  $\tau \in \{0, 1\}$  define a fração dos dados considerada como vetor de suporte.
- ❸ Os vetores de treinamento são ordenados de acordo com seus valores de  $\alpha$ .
- ❹ A fração  $(1 - \tau)$  dos dados de treinamento com os menores valores de  $\alpha$  é selecionada.
- ❺ Uma matriz não quadrada  $A_2$  é gerada removendo as colunas correspondentes aos dados selecionados no item anterior.
- ❻ O novo sistema de equações é resolvido,  $X_2 = A_2^+ B$ .
- ❼ Os vetores de suporte são os pontos de treinamento de  $A_2$ .
- ❽ Os valores de  $\alpha$  e  $b$  são obtidos da solução de  $X_2$ .

# RESULTADOS

- O método proposto é comparado com outras técnicas presentes na literatura:
  - SVM (QP).
  - $LS^2 - SVM$ .
  - Pruning.
  - ADA-PINV.
  - RRS+LS-SVM.
- São utilizados Kernels RBF e Linear.
- Quatro conjunto de dados do repositório da UCI são considerados, (Ionosphere, Pima Indians Diabetes, Bupa Liver Disorder e Tic Tac Toe).
- Dois conjuntos de dados sintéticos de duas dimensões são analisados para apresentar as superfícies obtidas.

# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método *ADA – Pinv* e kernel RBF (Problema dos três clusters). Fonte: Artigo base

# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método Pruning e kernel RBF (Problema dos três clusters). Fonte: Artigo base

# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método  $LS^2$  – SVM e kernel RBF (Problema dos três clusters). Fonte: Artigo base

# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método  $RRS + LS - SVM$  e kernel RBF (Problema dos três clusters). Fonte: Artigo base

# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método *SVM* e kernel RBF (Problema dos três clusters). Fonte: Artigo base



# RESULTADOS: SUPERFÍCIES




FIGURE: Superfície de Decisão obtida com o método  $IP - LSSVM$  e kernel RBF (Problema dos três clusters). Fonte: Artigo base

## RESULTADOS: ANÁLISE DO DESEMPENHO MÉDIO

- São apresentados os resultados médios para os 4 problemas considerando: Tempo de treinamento, Acurácia Média e Porcentagem de Vetores de Suporte ao longo de várias tabelas.
- Os resultados foram reduzidos a análise do método que obteve os melhores resultados.

# RESULTADOS: ANÁLISE DO DESEMPENHO MÉDIO

- São apresentados os resultados médios para os 4 problemas considerando: Tempo de treinamento, Acurácia Média e Porcentagem de Vetores de Suporte ao longo de várias tabelas.
- Os resultados foram reduzidos a análise do método que obteve os melhores resultados.

TABLE: Métodos que apresentaram os melhores resultados médios com kernel linear

Base	Tempo de Treinamento	Acurácia Média	Vetores
Ionosphere	IP-LSSVM	IP-LSSVM/ SVM	IP-LSSVM
Pima Indians	Pruning	Pruning	RRS+LS-SVM
Bupa Liver	IP-LSSVM	IP-LSSVM	IP-LSSVM/ADA
Tic Tac Toe	Pruning	$LS^2 - SVM$	IP-LSSVM/ADA

- Nota-se o método proposto é o que mais aparece entre os melhores resultados.

# RESULTADOS: ANÁLISE DO DESEMPENHO MÉDIO

TABLE: Métodos que apresentaram os melhores resultados médios com kernel RBF

Base	Tempo de Treinamento	Acurácia Média	Vetores
Ionosphere	IP-LSSVM	IP-LSSVM/* <sup>1</sup>	IP-LSSVM/* <sup>2</sup>
Pima Indians	IP-LSSVM	SVM	$LS^2 - SVM$
Bupa Liver	IP-LSSVM	$LS^2 - SVM$	IP-LSSVM/ADA
Tic Tac Toe	IP-LSSVM	ADA - PINV	IP-LSSVM/ADA

$$*^1 = LS^2 - SVM, \quad *^2 = LS^2 - SVM/ADA - PINV$$

- Nota-se o método proposto é o que mais aparece entre os melhores resultados.
- Valores numéricos podem ser consultados no artigo.
- A diferença entre a acurácia média entre os métodos é sempre menor que 5%.

# CONCLUSÃO

- Margem máxima é obtida pela formulação da programação quadrática, resultando em valores diferentes de zero para os multiplicadores de Lagrange próximo das margens de separação.

# CONCLUSÃO

- Margem máxima é obtida pela formulação da programação quadrática, resultando em valores diferentes de zero para os multiplicadores de Lagrange próximo das margens de separação.
- Alternativas a programação quadrática (LSSVM).

# CONCLUSÃO

- Margem máxima é obtida pela formulação da programação quadrática, resultando em valores diferentes de zero para os multiplicadores de Lagrange próximo das margens de separação.
- Alternativas a programação quadrática (LSSVM).
- As alternativas não são capazes de manter todas as características da formulação original.

# CONCLUSÃO

- Margem máxima é obtida pela formulação da programação quadrática, resultando em valores diferentes de zero para os multiplicadores de Lagrange próximo das margens de separação.
- Alternativas a programação quadrática (LSSVM).
- As alternativas não são capazes de manter todas as características da formulação original.
- Em particular, perda de dispersão ( '*sparseness*' ) no vetor dos multiplicadores de Lagrange.



# CONCLUSÃO

- Margem máxima é obtida pela formulação da programação quadrática, resultando em valores diferentes de zero para os multiplicadores de Lagrange próximo das margens de separação.
- Alternativas a programação quadrática (LSSVM).
- As alternativas não são capazes de manter todas as características da formulação original.
- Em particular, perda de dispersão ( '*sparseness*' ) no vetor dos multiplicadores de Lagrange.
- O método desenvolvido IP-LSSVM apresentou-se uma alternativa viável para detectar os vetores de suporte na margem, mantendo a simplicidade computacional do método LSSVM.

# AGRADECIMENTOS

- A todos os presentes pela atenção e suporte

Email:  
paulopessim777@hotmail.com